Lab 1 · Del texto a secuencias: tokenización, vocabulario y ley de Zipf

Aprendizaje Computacional II · Parte 2 (Modelado de secuencias) · Juan Carlos Alcausa Luque · Noviembre de 2026

Cuaderno entregado: `L1_resuelta.ipynb` (PyTorch 2.15 + d2l 1.0.0a0)

Resumen. Se convierte texto en secuencias de índices (tokenización y vocabulario) y se estudian sus estadísticas. En *The Time Machine* (inglés) la ley de Zipf se cumple con **α = 1,04** para palabras (R^2 = 0,99), y con exponentes menores para bigramas (0,65) y trigramas (0,38). En *Juvenilia* (español) se obtiene α = 0,93, 0,64 y 0,38. El español presenta más formas distintas y una cola algo más plana, aunque la magnitud de la diferencia depende del tamaño del corpus y del método de ajuste. Se revisan one-hot, BoW, TF-IDF y la perplejidad, que se calcula para modelos de n-gramas de caracteres.

1. Objetivos y metodología

1. Ejecutar el cuaderno proporcionado (descarga de *The Time Machine*, tokenización en caracteres, vocabulario, frecuencias y gráficas log-log de unigramas, bigramas y trigramas).
2. Ajustar linealmente el exponente de Zipf para unigramas, bigramas y trigramas, eliminando los valores de frecuencia muy alta y los de frecuencia 1, y medir la bondad del ajuste (R^2 y MSE).
3. Repetir el análisis con *Juvenilia* (español).
4. Comparar idiomas (palabras, caracteres y exponentes) y con la literatura, teniendo en cuenta el tamaño limitado de los corpus.
5. Revisar one-hot, TF-IDF y perplejidad.

Ajuste de Zipf. Regresión por mínimos cuadrados (MCO) de $\log_{10} n_i$ frente a $\log_{10} i$ ($\log n_i = -\alpha \log i + c$), usando los rangos $i > 10$ (se excluyen las *stop words* más frecuentes) y frecuencia ≥ 2 (se excluye la meseta de n-gramas que aparecen una vez). R^2 y MSE se calculan en el espacio log-log. Se estudia la sensibilidad a estos cortes.

Preprocesado del español. El regex del cuaderno, `[^A-Za-z]+`, rompe las palabras con tilde o ñ («música» → «m sica»). Se usa `[^a-záéíóúüñ]+`, que las conserva, y se compara con quitar las tildes con `Unidecode`.

2. Cuaderno base

El libro se descarga como una cadena de 178 979 caracteres. Tras pasar a minúsculas y sustituir cada racha de no-letras por un espacio, el corpus tiene **173 428 caracteres** y un vocabulario de **28** tokens (26 letras, espacio y `<unk>`); los más frecuentes son el espacio (18,9 %) y la «e» (10,3 %). La clase `Vocab` asigna los índices en orden alfabético y guarda las frecuencias ordenadas en `token_freqs`. A nivel de palabra hay 32 775 palabras y 4 579 distintas; las más frecuentes son *stop words* (the, i, and, of, a). Entre los bigramas, nueve de los diez más frecuentes son solo *stop words* (of the, in the, i had); entre los trigramas aparecen expresiones de la novela (the time traveller, the time machine).

3. Ejercicio 2 · Zipf en *The Time Machine*

n-grama	tipos	frecuencia 1	rangos ajustados	α	R^2	MSE ($\log_{10}^2$)
unigramas	4 579	52 %	11–2 182	**1,039**	0,990	0,0018
bigramas	20 234	82 %	11–3 609	**0,652**	0,965	0,0026
trigramas	29 882	95 %	11–1 631	**0,378**	0,889	0,0028

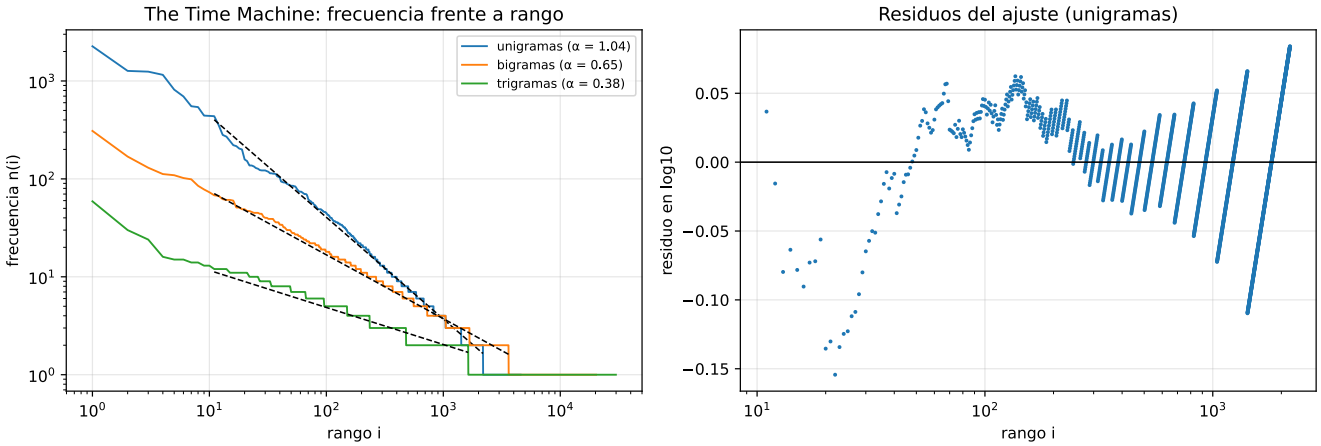


Figura 1. Frecuencia frente a rango con las rectas ajustadas, y residuos del ajuste de unigramas.

- Los unigramas cumplen muy bien la ley (α ≈ 1,04, R^2 ≈ 0,99), cerca del valor clásico α = 1. Bigramas y trigramas siguen también una ley de potencias con exponente menor: hay muchas más combinaciones y la frecuencia se reparte entre ellas.
- El ajuste empeora con n: el 95 % de los trigramas aparece una vez, quedan pocos puntos y la curva es escalonada.
- **Sensibilidad**: con 0, 10 o 50 rangos excluidos y frecuencia mínima 2 o 3, α de unigramas varía solo entre 1,03 y 1,06. Incluir la frecuencia 1 hunde α en bigramas (0,46) y trigramas (0,16) porque la meseta horizontal domina el ajuste.

4. Ejercicio 3 · *Juvenilia* (español)

El archivo contiene un prólogo, *Juvenilia* y *Prosa ligera*: 84 269 palabras (2,6 veces *The Time Machine*) y 13 547 distintas. Con tildes, el vocabulario de caracteres es de 35 (33 letras, espacio y `<unk>`). Palabras más frecuentes: de, la, que, el, y, en, a, los, un, su; bigramas: de la, en el, en la; trigramas: de la vida, uno de los, en la que.

n-grama	tipos	frecuencia 1	rangos ajustados	α	R^2	MSE ($\log_{10}^2$)
unigramas	13 547	57 %	11–5 804	**0,932**	0,988	0,0018
bigramas	53 916	84 %	11–8 553	**0,636**	0,965	0,0027
trigramas	78 165	96 %	11–3 474	**0,377**	0,900	0,0027

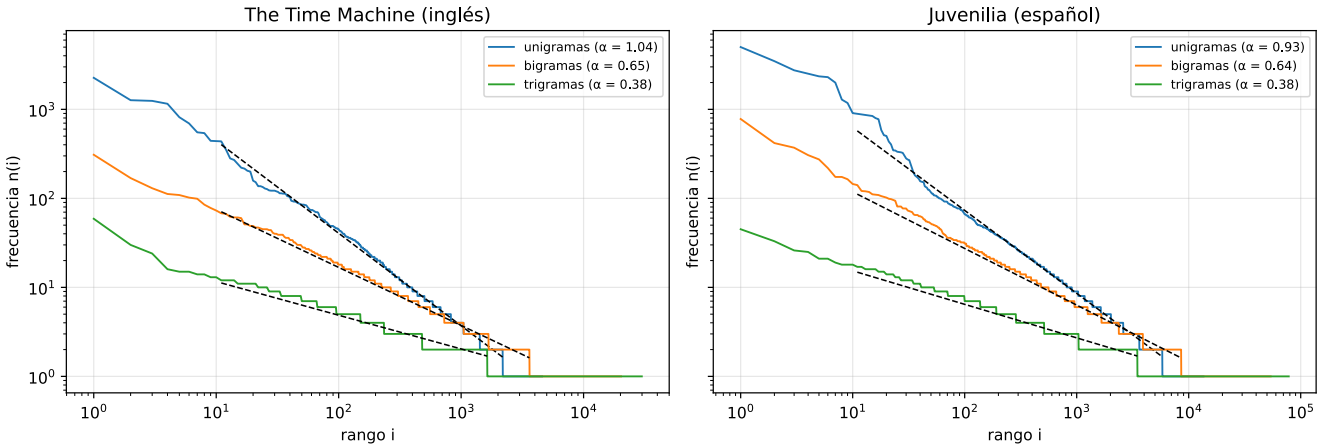


Figura 2. Ley de Zipf en inglés (izquierda) y en español (derecha), con las rectas ajustadas.

Quitar las tildes con Unidecode apenas cambia los exponentes (0,932 en unigramas en ambos casos), pero fusiona 165 formas distintas («él»/«el», «qué»/«que»).

5. Ejercicio 4 · Comparación entre idiomas

	Inglés: corpus grandes	***The Time Machine***	**Español: corpus grandes**	***Juvenilia***
Letras más frecuentes	e t a o i n s h r	e t a i n o s h r	e a o s r n i d l	e a o s n r i l d
Palabras más frecuentes	the, be, to, of, and, a, in (Oxford English Corpus)	the i and of a to was in that my	de, la, que, el, en, y, a, los (CREA)	de la que el y en a los un su
Longitud media de palabra	≈ 4,7	4,3	—	4,7
α unigramas	≈ 1	1,04	≈ 1	0,93

Para controlar el efecto del tamaño, se ajusta Zipf en fragmentos de *Juvenilia* con el mismo número de palabras que *The Time Machine*, y también con un ajuste por intervalos (media de los puntos en 20 intervalos de igual anchura en log i), que evita que la cola domine la recta:

corpus	**palabras**	**tipos**	**α uni (MCO)**	**α uni (intervalos)**	**α bi (MCO)**	**α tri (MCO)**
The Time Machine (completo)	32 775	4 579	1,039	1,010	0,652	0,378
Juvenilia completo	84 269	13 547	0,932	0,982	0,636	0,377
Juvenilia, primeras 32 775	32 775	7 545	0,858	0,964	0,574	0,300
Juvenilia, central 32 775	32 775	7 298	0,868	0,959	0,583	0,304
Juvenilia, últimas 32 775	32 775	6 962	0,899	0,974	0,590	0,319

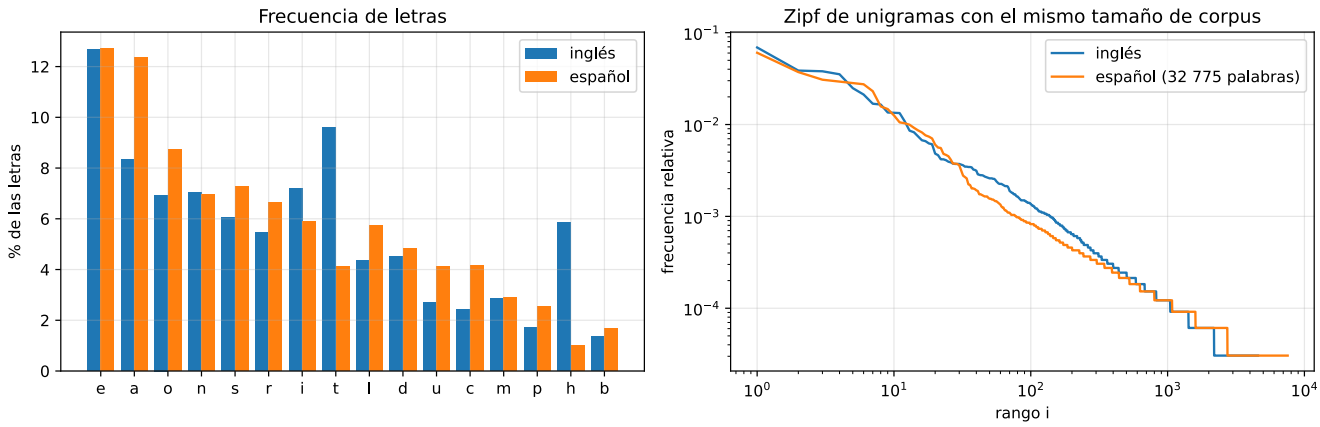


Figura 3. Frecuencia de letras y ley de Zipf de unigramas con el mismo tamaño de corpus.

- **Caracteres.** La «e» es la letra más frecuente en ambos idiomas (≈ 12,7 % de las letras). El inglés usa mucho la «t» y la «h» (the, that); el español, la «a», la «o» y la «s» (género y plurales). Los órdenes coinciden casi exactamente con los de corpus grandes: con pocas letras repetidas miles de veces, un libro basta.
- **Palabras.** En ambos dominan las *stop words*, como en los grandes corpus. «i» (2.º) y «my» (10.º) reflejan la narración en primera persona de la novela. Con el mismo número de palabras, el español tiene ≈ 7 000–7 500 formas distintas frente a 4 579 en inglés, por su morfología más rica (conjugaciones, género y número).
- **Exponentes.** Ambos idiomas cumplen Zipf con α cercano a 1, el valor descrito para corpus grandes. El español tiene una cola más pesada (α menor). La magnitud depende del método: con el mismo tamaño y MCO la diferencia crece (1,04 frente a 0,86–0,90); con el ajuste por intervalos casi desaparece (1,01 frente a 0,96–0,97). Con los corpus completos, bigramas y trigramas tienen exponentes casi iguales.
- **Limitaciones.** Más de la mitad del vocabulario aparece una sola vez (52 % y 57 %), lo que hace la cola poco fiable y α sensible a los cortes, sobre todo en trigramas. Un único autor y género no representan un idioma, y comparar exponentes exige el mismo tamaño y el mismo método.

6. Ejercicio 5 · Codificaciones y perplejidad

- **One-hot**: con el vocabulario {h:0, e:1, l:2, o:3}, «hello» es una matriz 5 × 4 con un 1 por fila; los 10 primeros caracteres del libro, una matriz 10 × 28. No codifica ninguna relación entre tokens y su tamaño crece con el vocabulario (4 580 componentes con palabras).
- **BoW**: los caracteres de «cat in the hat» con el vocabulario [c, a, t, ' ', i, n, h, e] dan [1, 2, 3, 3, 1, 1, 2, 1]. La diapositiva indica 2 para la «t», pero aparece 3 veces. «the in cat hat» da el mismo vector: el BoW pierde el orden.
- **TF-IDF** (dos documentos, IDF con $\log_{10}$): «the» y «cat» están en ambos y obtienen 0; las palabras exclusivas obtienen (1/6)·log 2 ≈ 0,05 en el primero y (1/5)·log 2 ≈ 0,06 en el segundo, como en las diapositivas.
- **Perplejidad**: PP = $P(W)^{-1/n}$ = exp(entropía cruzada). Para «a red fox.», P = 0,4·0,27·0,55·0,79 = 0,0469 y PP = 2,15; un modelo uniforme sobre 6 palabras da PP = 6.

Se calcula la perplejidad en test (10 % final del texto) de modelos de n-gramas de caracteres entrenados por conteo con suavizado de Laplace:

n	inglés (|V| = 27)	español con tildes (|V| = 34)	español Unidecode (|V| = 27)
1	16,73	17,02	15,82
2	9,61	9,44	8,95
3	6,51	6,74	6,52
4	5,41	5,48	5,21
5	6,19	5,81	5,22
6	8,22	7,62	6,50

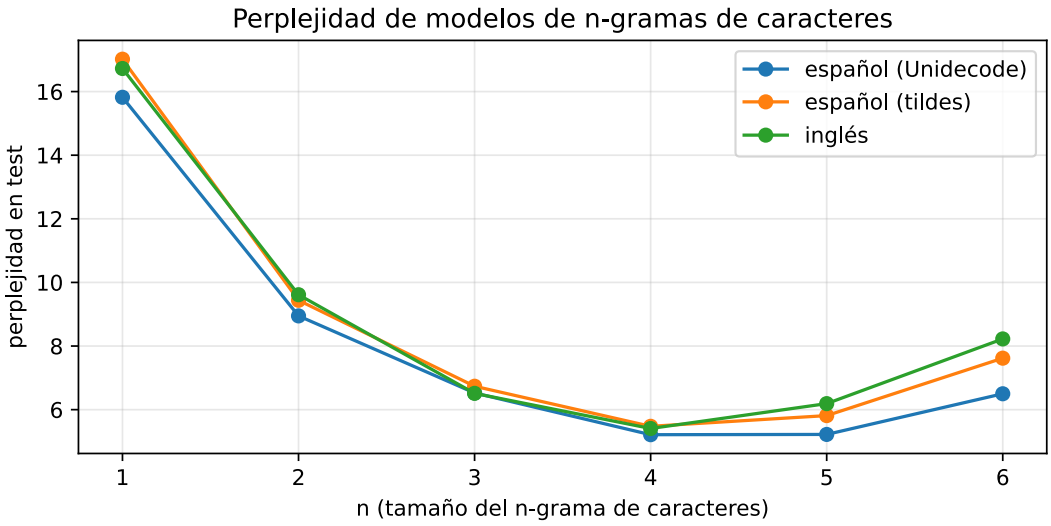


Figura 4. Perplejidad en test frente al tamaño del n-grama.

Sin contexto (n = 1) la perplejidad ya baja de |V| a ≈ 16–17 porque las letras no son equiprobables. Con 3 caracteres de contexto (n = 4) alcanza ≈ 5,2–5,5. Con n = 5 deja de mejorar y con n = 6 empeora: la mayoría de los contextos largos aparecen pocas veces o ninguna (la cola de Zipf) y un modelo de conteo no generaliza. Inglés y español se comportan de forma parecida a nivel de carácter.

7. Conclusiones

- El texto se convierte en secuencias con el flujo cargar → preprocesar → tokenizar → vocabulario → índices. La elección del token y el preprocesado dependen del idioma: el regex del inglés destruye las palabras con tilde o ñ.
- La ley de Zipf se cumple en ambos idiomas: $\alpha \approx 1$ para palabras (1,04 en inglés, 0,93 en español) y exponentes menores para bigramas (≈ 0,65) y trigramas (≈ 0,38).
- El español tiene más formas distintas y una cola más plana, pero la comparación de exponentes es sensible al tamaño del corpus, a los cortes y al método de ajuste.
- La abundancia de palabras y n-gramas raros limita a los modelos basados en contar (la perplejidad de los n-gramas empeora con contextos largos) y motiva los modelos neuronales que se estudiarán en el Lab 2.