Lab 0 · Trabajando con secuencias: modelos autorregresivos

Aprendizaje Computacional II · Parte 2 (Modelado de secuencias) · Juan Carlos Alcausa Luque · Noviembre de 2026

Cuaderno entregado: `P0_resuelta.ipynb` (PyTorch 2.15 + d2l 1.0.0a0)

Resumen. Se estudia un modelo autorregresivo (AR) lineal, que predice x_t a partir de los τ valores anteriores. Sobre una serie sintética (seno con ruido de varianza 0,04) el error a un paso cae rápidamente hasta τ ≈ 8–12 y se estabiliza cerca del mínimo teórico; se elige **τ = 12** (MSE 0,047). Al predecir k pasos realimentando las predicciones, el error crece con el horizonte (0,051 → 0,278 de k = 1 a k = 64). Con datos reales, el AR mejora a la persistencia en temperaturas diarias (MAE 1,79 °C frente a 2,01 °C, τ = 21 días) pero no en la cotización de IBM, que se comporta como un paseo aleatorio. Se discute la diferencia entre modelos AR y AR latentes.

1. Objetivos y metodología

El enunciado pide: (1) variar el número de observaciones anteriores τ y graficar el error frente a τ; (2) con un τ elegido, comparar predicciones a distintos horizontes; (3) repetir el análisis con datos reales (IBM o temperaturas) calculando MAE o MSE; (4) comparar modelos autorregresivos y autorregresivos latentes.

- **Modelo.** Ventana deslizante: características $[x_{t-\tau}, \ldots, x_{t-1}]$ y etiqueta x_t. Modelo lineal $\hat{x}_t = c + \Sigma\, \phi_i\, x_{t-i}$ (`nn.Linear(τ, 1)`), pérdida MSE, SGD con η = 0,01, lotes de 16 y 10 épocas, igual que `d2l.LinearRegression` + `d2l.Trainer`.
- **Referencia exacta.** Como el modelo es lineal, se calcula también la solución por mínimos cuadrados (MCO). Si SGD se aleja de ella, el problema es de optimización y no del modelo.
- **Partición temporal fija.** Nunca se baraja la serie antes de partirla. En la serie sintética, las etiquetas $t \leq 600$ entrenan y $t = 601 \ldots 1000$ evalúan para cualquier τ, de modo que todos los modelos se comparan sobre los mismos valores.
- **Varias semillas.** En la serie sintética se promedian 10 semillas (ruido, inicialización y orden de lotes) para separar efectos reales del azar.
- **Métricas.** MSE = media de $(\hat{x}_t - x_t)^2$; MAE = media de $|\hat{x}_t - x_t|$.

Detalle de d2l. `LinearRegression` crea una `nn.LazyLinear(1)` y llama a `weight.data.normal_(0, 0.01)`; como una capa *lazy* no tiene pesos hasta la primera pasada, esa llamada no tiene efecto y los pesos usan la inicialización por defecto de PyTorch. La reimplementación del cuaderno reproduce ese comportamiento.

2. Cuaderno base: seno con ruido y τ = 4

Se generan 1 000 puntos de $x_t = \sin(0{,}01t) + \varepsilon_t$ con $\varepsilon_t \sim N(0;\, 0{,}2^2)$. El ruido es blanco, así que su varianza (**0,04**) es el MSE mínimo que puede alcanzar cualquier modelo. Con τ = 4 hay 996 ejemplos (600 de entrenamiento). La predicción a un paso sigue bien la serie (MSE ≈ 0,06), pero al realimentar las predicciones desde $t = 605$ la curva se aplana hacia una constante: los errores se acumulan.

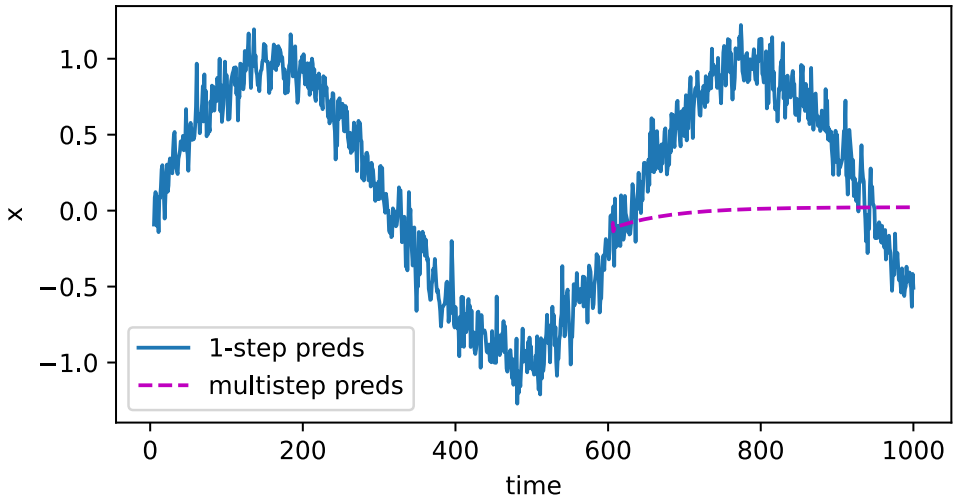


Figura 1. Predicción a un paso frente a predicción realimentada desde t = 605 (cuaderno base, τ = 4).

3. Ejercicio 1 · Influencia de τ

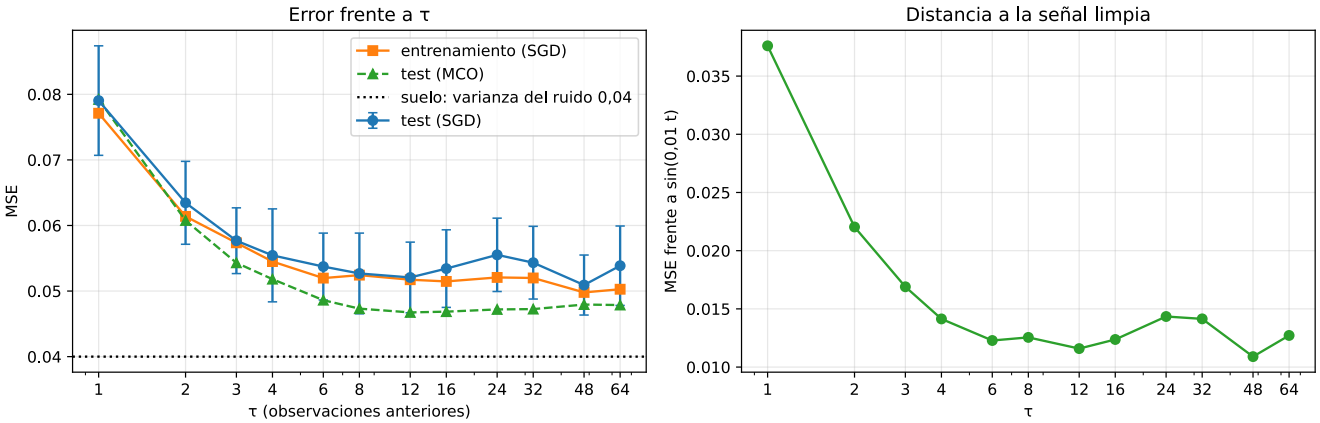


Figura 2. MSE frente a τ (media de 10 semillas; barras = desviación típica) y distancia a la señal limpia.

τ	MSE train (SGD)	MSE test (SGD)	desv.	MSE frente a la señal	MSE test (MCO)
1	0,0771	0,0790	0,0084	0,0376	0,0792
2	0,0614	0,0635	0,0063	0,0220	0,0608
4	0,0545	0,0554	0,0071	0,0141	0,0518
8	0,0524	0,0527	0,0062	0,0125	0,0473
12	**0,0517**	**0,0521**	**0,0054**	**0,0116**	**0,0467**
16	0,0515	0,0534	0,0059	0,0124	0,0469
32	0,0520	0,0543	0,0055	0,0141	0,0472
48	0,0498	0,0509	0,0046	0,0109	0,0479
64	0,0503	0,0539	0,0061	0,0127	0,0479

El MSE de test se descompone en error frente a la señal limpia más la varianza del ruido (0,04), y la tabla lo confirma. Conclusiones:

- Con τ = 1 el error es alto (0,079): la predicción casi copia el último valor, que lleva todo su ruido.

- El error cae rápidamente hasta τ ≈ 8–12. La solución MCO alcanza su mínimo en **τ = 12 (0,0467)**, muy cerca del suelo de 0,04. El modelo aprende una media ponderada de la ventana (pesos que suman ≈ 1, figura 3), que reduce el ruido; el seno cambia tan despacio (periodo ≈ 628 pasos) que en la ventana apenas varía.
- Por encima de τ ≈ 12 no se gana nada: MCO empeora ligeramente (0,048 con τ = 48–64) porque hay más parámetros con los mismos 600 ejemplos.
- SGD queda ≈ 0,005 por encima de MCO: 10 épocas no bastan para converger. Las diferencias entre τ ≥ 6 están dentro de la variación entre semillas.
- **Se elige τ = 12**: mínimo de MCO y menor τ cuyo error SGD está a menos de un error estándar del mejor (regla 1-SE). Entrenamiento ≈ test: no hay sobreajuste.

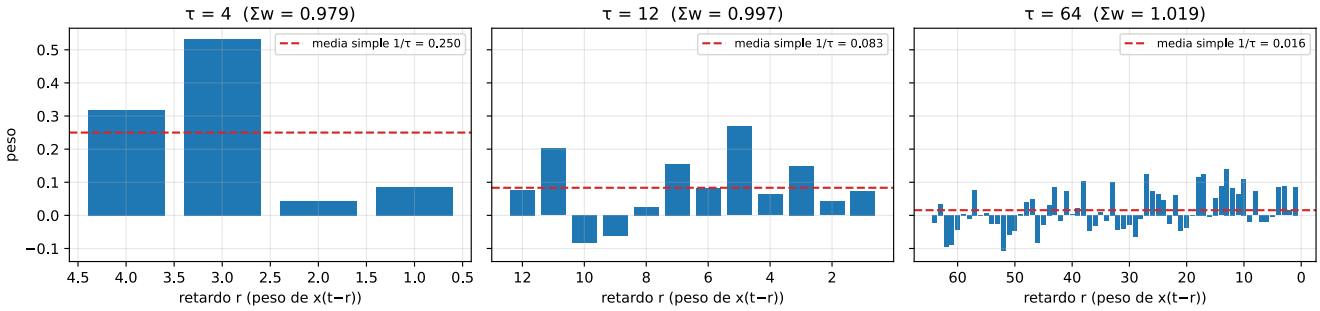


Figura 3. Pesos aprendidos (SGD, semilla 0) para τ = 4, 12 y 64.

4. Ejercicio 2 · Predicción a distintos horizontes (τ = 12)

Cada valor de test se predice usando solo datos hasta *t* - *k* y realimentando k veces, siempre sobre los mismos objetivos (*t = 665…1000*). Se incluyen τ = 4 y τ = 64 como contraste.

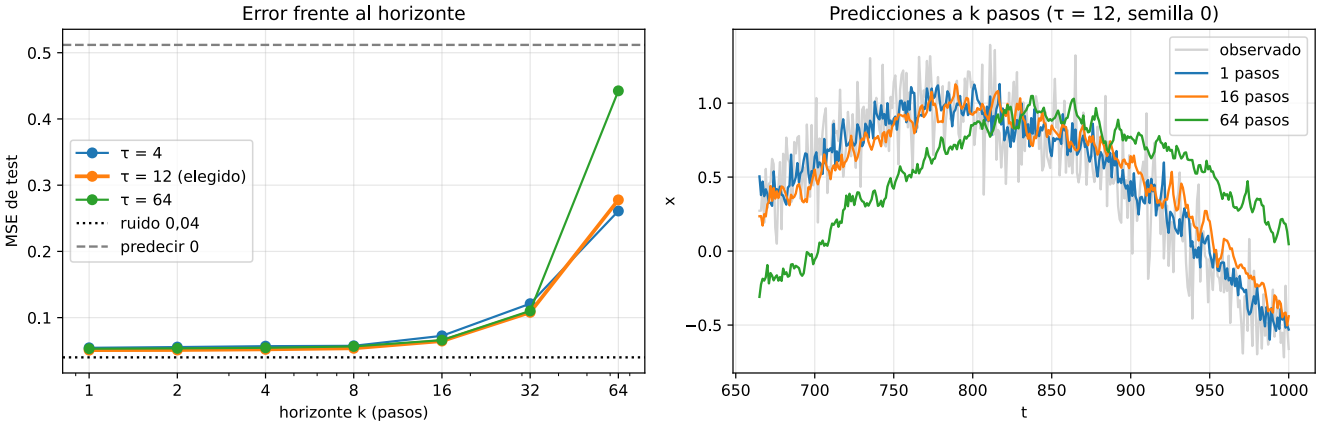


Figura 4. Izquierda: MSE frente a k (10 semillas). Derecha: predicciones a 1, 16 y 64 pasos con τ = 12.

k	MSE τ = 4	MSE τ = 12	MSE τ = 64	MAE τ = 12
1	0,054	0,051	0,053	0,179
2	0,056	0,051	0,054	0,180
4	0,057	0,052	0,054	0,182
8	0,057	0,054	0,057	0,185
16	0,072	0,065	0,066	0,205
32	0,121	0,108	0,110	0,270
64	0,261	0,278	0,442	0,456

- Con τ = 12 el error apenas cambia hasta k = 8 (la ventana aún contiene muchos datos reales), crece a partir de k = 16 y a k = 64 es **más de 5 veces** el error a un paso (0,278), aunque sigue por debajo de predecir siempre 0 (MSE 0,51).
- Una ventana mayor no mejora el largo plazo: a k = 64, τ = 64 es el peor (0,44).
- La **predicción libre** desde t = 601 es una recurrencia lineal cuyo comportamiento depende del radio espectral ρ de la matriz compañera: con τ = 4 (ρ = 0,992) decae a una constante; con τ = 12 (ρ = 0,999) queda casi congelada; con τ = 64 (ρ = 1,007) deriva. MSE libre mediano: 0,53, 0,90 y 3,71.

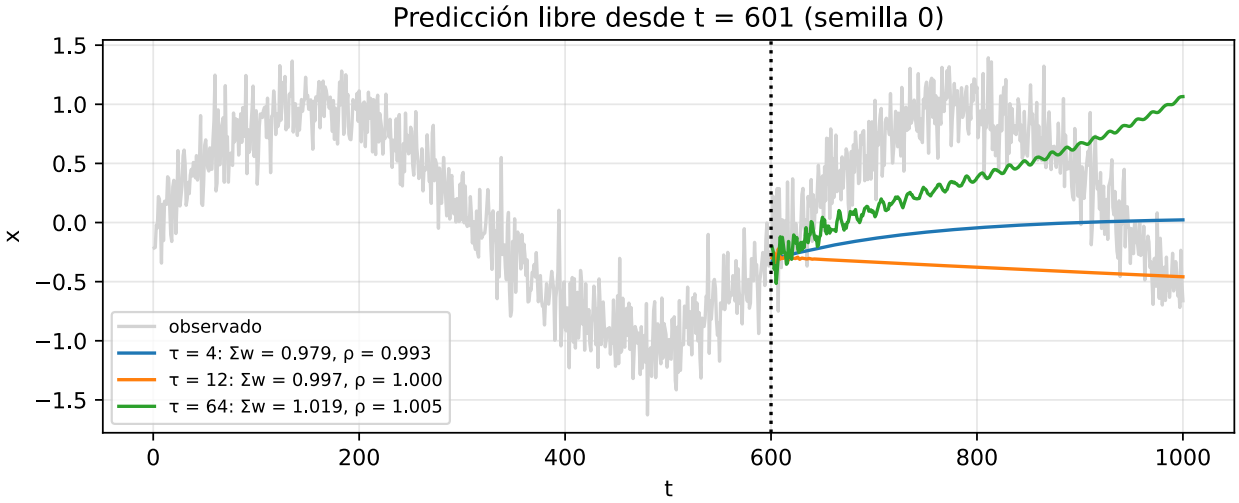


Figura 5. Predicción libre desde t = 601 para τ = 4, 12 y 64.

5. Ejercicio 3 · Datos reales

5.1 Temperaturas mínimas diarias (Melbourne, 1981–1990)

3 650 días con ciclo anual. Partición temporal 70/30 (1981–1987 entrena, 1988–1990 evalúa). Se estandariza con la media y la desviación **del entrenamiento** y los errores se expresan en °C. Se compara con tres referencias ingenuas: **persistencia** (mañana igual que hoy), **estacional** (mismo día del año anterior) y **climatología** (media de entrenamiento).

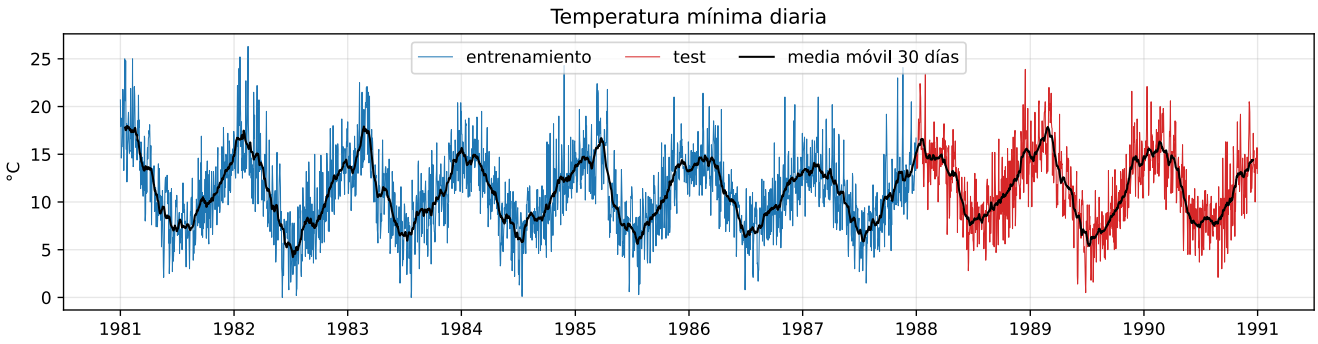


Figura 6. Serie de temperaturas y partición entrenamiento/test.

τ (días)	MAE MCO (°C)	MSE MCO (°C²)	MAE SGD (°C)	$2 \cdot \eta \cdot \lambda_{max}$ por lote
1	1,932	6,00	1,929	0,02
3	1,879	5,73	1,881	0,05
7	1,818	5,34	1,818	0,10
14	1,795	5,23	1,798	0,18
21	**1,790**	**5,22**	**1,828**	**0,26**
30	1,796	5,25	1,799	0,35
60	1,813	5,30	1,854	0,64
180	1,853	5,45	2,115	1,27
365	1,976	6,26	6,704	2,49
persistencia	2,012	6,67	—	—
estacional (año anterior)	3,016	14,41	—	—
climatología (media)	3,327	16,38	—	—

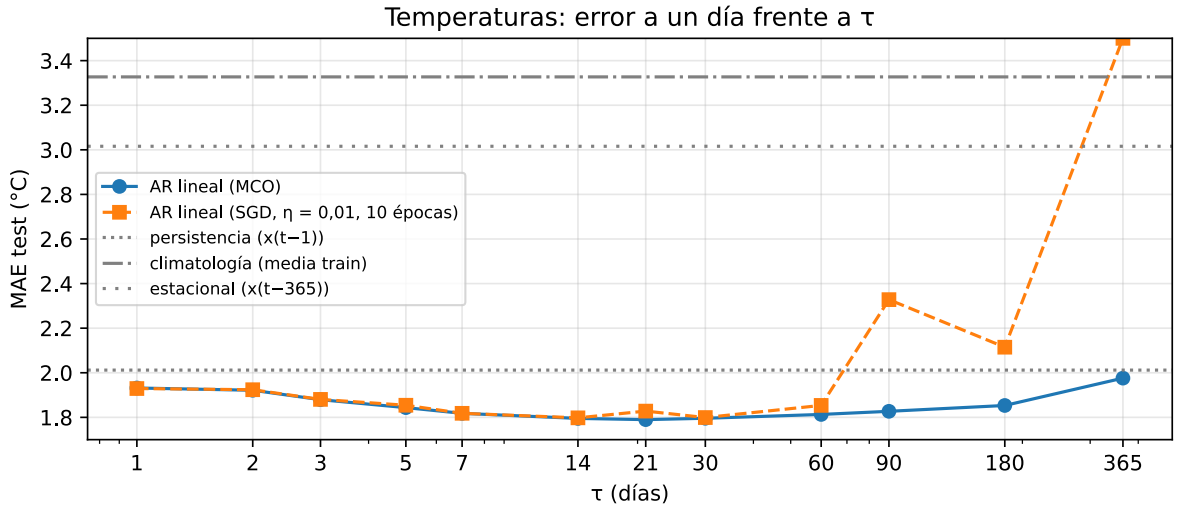


Figura 7. MAE a un día frente a τ y referencias ingenuas.

- A un día, el mejor τ es **21 días** (14 da casi lo mismo): MAE 1,79 °C y MSE 5,22 °C², un 11 % y un 22 % mejor que la persistencia (2,01 °C; 6,67 °C²). El error forma una U suave frente a τ.
- **SGD diverge con τ = 365** (MAE 6,7 °C). La pérdida es una parábola de curvatura $H = 2X^TX/n$; el descenso por gradiente solo es estable si $\eta\ \lambda_{max}(H) < 2$, y con entradas estandarizadas muy

correlacionadas λ_{max} crece con τ hasta superar ese límite (≈ 2,5 por lote). Con τ = 90–180 no diverge pero no converge en 10 épocas. MCO muestra el comportamiento real del modelo.

k (días)	AR τ = 21	AR τ = 365	persistencia	estacional	climatología
1	1,80	1,98	2,03	2,98	3,25
2	2,03	2,24	2,60	2,98	3,25
3	2,09	2,28	2,77	2,98	3,25
7	2,15	2,31	2,78	2,98	3,25
14	2,27	2,35	2,93	2,98	3,25
30	2,51	2,42	3,03	2,98	3,25
60	3,07	2,42	3,82	2,98	3,25

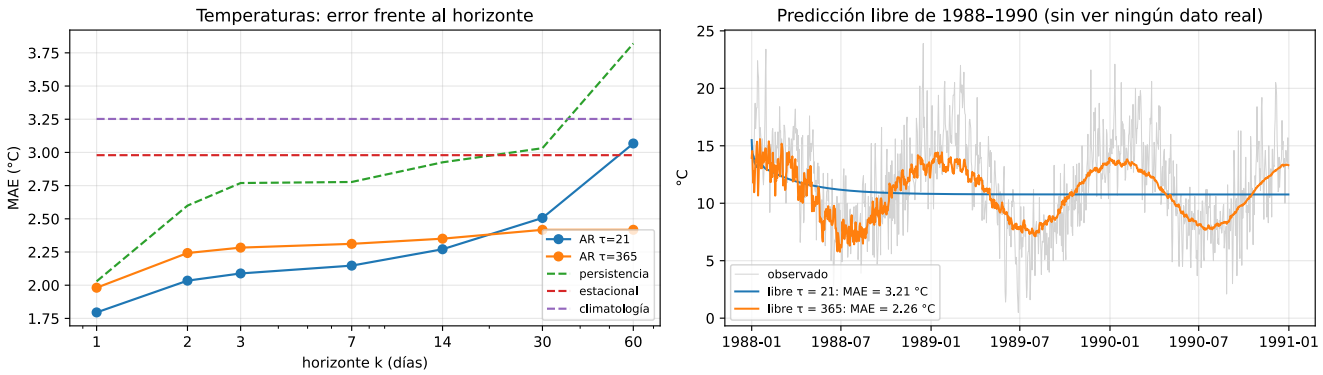


Figura 8. MAE (°C) frente al horizonte y predicción libre de 1988–1990 con τ = 21 y τ = 365.

- Con τ = 21 el MAE pasa de 1,80 °C (k = 1) a 3,07 °C (k = 60), ya peor que la referencia estacional; su predicción libre se aplana en la media (MAE 3,21 °C).
- Con τ = 365 el modelo es peor a un día (1,98 °C) pero el mejor desde k ≈ 30 (2,42 °C), y su predicción libre **reproduce el ciclo estacional** durante tres años (MAE 2,26 °C). Para captar dependencias largas, un AR de ventana fija necesita ventanas muy grandes.

5.2 Complemento: cotización de IBM (2010–2017)

Precio de cierre diario (1 980 sesiones, partición 70/30). AR por MCO con τ = 5; pesos de x_{t-5} a x_{t-1}: [0,019; 0,015; –0,053; 0,016; 0,998].

k (días)	MAE AR τ = 5 (USD)	MAE persistencia (USD)
1	1,11	1,12
2	1,64	1,64
5	2,69	2,72
10	3,81	3,88
20	5,83	5,99
60	10,98	11,84

- El AR **redescubre la persistencia** (peso ≈ 1 en el último día) y no la mejora: MAE ≈ 1,17 USD a un día. Más historia no aporta (1,21 USD con τ = 60).

- El error crece aproximadamente como √k y las rentabilidades diarias no son predecibles (MSE del AR 1,102 frente a 1,101 prediciendo 0): comportamiento de **paseo aleatorio**.
- Contraste: la temperatura tiene inercia y estacionalidad que un AR aprovecha; la bolsa no. Un error solo tiene sentido comparado con una referencia ingenua.

6. Ejercicio 4 · Modelos autorregresivos frente a autorregresivos latentes

Modelo autorregresivo. Predice a partir de una ventana fija, $\hat{x_t} = f(x_{t-1}, \ldots, x_{t-\tau})$. Supone la condición de Markov de orden τ: lo anterior a $x_{t-\tau}$ no aporta. Si una dependencia es más larga que la ventana, el modelo no puede verla, y ampliar la ventana aumenta los parámetros y los datos necesarios.

Modelo autorregresivo latente. Mantiene un estado oculto que resume el pasado y lo actualiza en cada paso:

$$h_t = g(h_{t-1}, x_{t-1}), \quad \hat{x_t} = P(x_t \mid h_t)$$

El estado tiene tamaño fijo pero puede conservar información de cualquier momento anterior; los parámetros no crecen con la longitud de la historia. Es la idea de las RNN, LSTM, filtros de Kalman y modelos ocultos de Markov.

Ejemplos que requieren variables latentes:

1. **La estación del año (resultado del ejercicio 3).** Para reproducir el ciclo anual, el AR necesitó 365 entradas y 365 pesos. Lo que determina la temperatura esperada es una variable no observada directamente, la fase del año (y, a otra escala, la situación meteorológica). Un modelo latente puede llevarla en un estado de 1–2 números que avanza cada día, en lugar de memorizar un año de datos.
2. **Lenguaje.** En «Las llaves que dejé ayer encima de la mesa del salón *están*…», el verbo concuerda con una palabra lejana y la distancia no está acotada: ninguna ventana fija sirve siempre. Del mismo modo, para saber si hay que cerrar un paréntesis hay que contar los abiertos; ese contador es una variable latente.
3. **Regímenes ocultos en finanzas.** La volatilidad alterna entre épocas tranquilas y de crisis; el régimen no se observa, pero determina cuánto se moverá el precio. Los modelos de cambio de régimen lo tratan como una variable latente inferida a partir de toda la historia.

7. Conclusiones

- Las ventanas deslizantes convierten una serie en un problema supervisado; el AR lineal es una capa lineal entrenada con MSE, y tiene solución cerrada por mínimos cuadrados.
- Elegir τ es un compromiso: una ventana corta no filtra el ruido; una larga añade parámetros y varianza sin información nueva (τ = 12 en el seno; 2–3 semanas en temperaturas).
- Predecir un paso es fácil; al realimentar, los errores se acumulan y el AR lineal tiende a su punto fijo o diverge según su estabilidad.
- La metodología importa: partición temporal, estadísticos solo del entrenamiento, varias semillas y comparación con referencias ingenuas. El AR bate claramente a la persistencia en temperaturas, pero no en bolsa.
- Con SGD, ventanas largas exigen una tasa de aprendizaje menor (condición $\eta \cdot \lambda_{max} < 2$).

- Las dependencias largas requieren ventanas enormes en un AR; los modelos con estado latente (RNN, LSTM), que se estudian en los siguientes labs, resuelven este problema.